本科毕业论文（设计）

基于多模态大模型的语音导览助手

RESEARCH ON Voice Guide Assistant Based on Multimodal Large Language Models

李炜臻

哈尔滨工业大学

2025 年 6 月

☑毕业论文　☐毕业设计　　密级：公开

本科毕业论文（设计）

基于多模态大模型的语音导览助手

本　　科　　生：李炜臻

学　　号：220110717

指　导　教　师：韩亮教授

专　　业：计算机科学与技术

学　　院：深圳校区计算机科学与技术学院

答　辩　日　期：2026 年 5 月

学　　校：哈尔滨工业大学

摘 要

随着智慧博物馆和数字文化遗产建设的推进，博物馆导览服务正从固定文本展示和单向语音播放，逐步转向面向观众兴趣的智能化、交互式和个性化服务。传统导览方式能够提供基础展品介绍，但在自由问答、图像输入、知识更新和讲解生成方面仍存在不足。近年来，大语言模型、多模态大模型、检索增强生成、图文对齐和神经语音合成技术快速发展，为构建能够理解观众问题、识别文物图像并生成自然讲解的智能导览系统提供了新的技术基础。针对文物导览任务中专业知识密集、事实准确性要求高和用户输入形式多样等特点，本文研究并实现了一种基于多模态大模型的文物语音导览问答系统。

本文首先构建面向文物导览场景的半结构化知识库，将文物名称、所属时代、类别、馆藏单位、材质、功能用途、文化价值和历史背景等信息组织为可检索文本。随后，以文本向量表示和 FAISS 相似度检索为基础，构建文本检索增强问答链路，使生成模型能够依据外部文物资料回答用户问题。针对观众在参观过程中可能“不知道文物名称但可以拍照提问”的场景，本文设计两条多模态问答路线：方案 A 采用“CLIP 图像检索 + 文本 RAG”的可解释流水线，先通过图像向量检索识别候选文物，再调用文本知识库生成回答；方案 B 采用多模态大模型直接接收图像与问题，并进一步设置 direct 与 grounded 两种模式，用于分析端到端多模态问答与知识库增强问答之间的差异。系统还集成文本转语音模块和 Streamlit 交互界面，形成从图片或文本输入、知识检索、答案生成到语音播报的完整导览流程。

实验基于 199 个文物图像样本和 1592 个问答样本展开。结果表明，方案 A 在图像识别和事实链路上表现稳定，图像识别名称准确率达到 1.000，事实答案准确率达到 0.964，导览质量裁判通过率达到 0.9552；方案 B 的 direct 模式缺少外部知识约束，自动准确率仅为 0.107，导览质量通过率为 0.1560；方案 B 的 grounded 模式在加入检索上下文后显著提升，自动准确率达到 0.804，语义裁判通过率达到 0.876，导览质量通过率达到 0.8431。实验结果说明，在文物导览这类知识密集型任务中，单纯依赖端到端多模态大模型并不稳定，图像检索、文本检索和知识 grounding 仍是提升回答可靠性的关键。本文工作为多模态大模型在文博导览场景中的落地应用提供了一套可实现、可评测和可扩展的系统方案。

关键词：智慧博物馆；多模态大模型；检索增强生成；文物问答；图像检索；语音导览

Abstract

With the development of smart museums and digital cultural heritage services, museum guide systems are evolving from fixed exhibit descriptions and one-way audio playback toward intelligent, interactive, and personalized services. Traditional guide systems can provide basic introductions, but they are limited in open-ended question answering, image-based interaction, knowledge updating, and adaptive explanation generation. Recent advances in large language models, multimodal large language models, retrieval-augmented generation, vision-language alignment, and neural text-to-speech provide new opportunities for building intelligent guide systems that can understand visitor questions, recognize artifact images, and generate natural explanations. Considering the knowledge-intensive nature of artifact interpretation and the high requirement for factual reliability, this thesis studies and implements a multimodal large-model-based speech guide question-answering system for museum artifacts.

This work first constructs a semi-structured artifact knowledge base containing artifact names, periods, categories, museums, materials, functions, cultural values, and historical backgrounds. Based on text embeddings and FAISS similarity search, a retrieval-augmented question-answering pipeline is built to ground model responses in external artifact knowledge. To support realistic visiting scenarios where users may not know artifact names but can ask questions with photos, two multimodal schemes are designed. Scheme A is an interpretable pipeline combining CLIP-based image retrieval and text RAG. It identifies candidate artifacts through image-vector retrieval and then generates answers based on textual knowledge. Scheme B sends the image and question directly to a multimodal large language model, with both direct and grounded modes for comparison. The system also integrates text-to-speech and a Streamlit interface, forming a complete workflow from text or image input to knowledge retrieval, answer generation, and speech output.

Experiments are conducted on 199 artifact images and 1592 question-answer samples. The results show that Scheme A is stable in image recognition and factual grounding, achieving an artifact-name recognition accuracy of 1.000, a factual answer accuracy of 0.964, and a guide-quality pass rate of 0.9552. Scheme B in direct mode performs poorly without external knowledge grounding, with an automatic accuracy of 0.107 and a guide-quality pass rate of 0.1560. After incorporating retrieved context, Scheme B in grounded mode improves

significantly, achieving an automatic accuracy of 0.804, a semantic-judge pass rate of 0.876, and a guide-quality pass rate of 0.8431. These results indicate that, for knowledge-intensive museum guide tasks, relying solely on end-to-end multimodal models is unstable, while image retrieval, text retrieval, and knowledge grounding remain essential for reliable responses. This work provides an implementable, evaluable, and extensible engineering reference for applying multimodal large models to cultural heritage guide systems.

Keywords: Smart Museum,Multimodal Large Language Model,Retrieval-Augmented Generation;Artifact Question Answering,Image Retrieval,Speech Guide

目　录

摘　要 I
Abstract III
第 1 章 绪　论 1
1.1 课题背景 1
1.2 研究目的与意义 1
1.3 相关研究 2
1.3.1 智慧博物馆与数字文化遗产 2
1.3.2 检索增强生成与领域问答 3
1.3.3 向量检索与图像检索 3
1.3.4 多模态大模型与视觉问答 3
1.3.5 语音合成与生成质量评价 4
1.4 本文的主要研究内容 4
第 2 章 方法框架 6
2.1 总体框架 6
2.2 文本 RAG 问答方法 6
2.3 方案 A：图像检索增强式问答 6
2.4 方案 B：多模态大模型问答 7
第 3 章 系统构建 8
3.1 文物知识库构建 8
3.2 文本索引与图像索引构建 8
3.3 提示词与模型调用 8
3.4 语音输出与交互界面 9
3.5 离线评测流程 9
第 4 章 实验与结果分析 10
4.1 实验设置 10
4.2 评价指标 10
4.3 方案 A 实验结果 11
4.4 方案 B 实验结果 12
4.5 导览讲解质量评价 13

4.6 综合对比与误差分析 14
结　论 16
参考文献 18
哈尔滨工业大学本科毕业论文（设计） 原创性声明和使用权限 20
致　谢 21

第 1 章　绪　论

1.1 课题背景

博物馆承担着文化遗产保护、历史知识传播和公共教育的重要职能。随着数字化建设和公共文化服务水平的提升，观众对博物馆导览的期待已经不再局限于固定展签、人工讲解或预录音频，而是希望能够围绕个人兴趣进行主动提问，并获得及时、自然、可信的解释。智慧博物馆研究通常强调展品、空间、观众和服务平台之间的协同，通过物联网、移动终端和智能交互增强文化空间的服务能力[1]。国内相关研究也指出，智慧博物馆建设正在由单纯的信息化管理扩展到藏品数据组织、数字人文研究和沉浸式体验等方向[2-4]。增强现实、虚拟现实和混合现实等技术在文化遗产展示中的应用进一步表明，博物馆导览正在从“展示内容”转向“构建体验”[5]。

在人工智能技术快速发展的背景下，大语言模型为自然语言问答和讲解生成提供了新的可能。Transformer 架构通过自注意力机制提升了长距离依赖建模能力[6]，成为当前大语言模型和多模态大模型的重要基础。大语言模型能够理解自然语言问题并生成流畅文本，多模态大模型则能够处理图像与文本联合输入，使用户可以通过“拍照 + 提问”的方式与系统交互。然而，文物导览并不是开放式聊天任务。文物名称、年代、馆藏单位、历史背景和文化价值等信息具有较强专业性，错误讲解不仅影响用户体验，也可能造成文化知识传播偏差。因此，如何在利用大模型生成能力的同时，引入可追溯、可更新的文物知识，是本文关注的核心问题。

检索增强生成为缓解大模型事实幻觉提供了有效路径。该方法将外部知识检索与生成模型结合，使模型在知识密集型任务中能够依据检索证据生成回答[7]。在文物导览场景中，文物资料可以被组织为知识库，并通过向量检索召回与用户问题相关的条目。对于图像输入，还可以借助图文对齐模型进行图像检索，将用户拍摄图片映射到候选文物，再进入文本问答流程。由此，智能导览系统可以同时兼顾图像交互、知识 grounding 和自然语言表达。

1.2 研究目的与意义

本文的研究目的在于构建一个面向博物馆文物讲解场景的智能语音导览原型系统，使其具备自然语言问答、图片识别问答、知识库增强生成和语音播

报能力。系统不以通用聊天为目标，而是强调文物领域知识的准确性、回答过程的可追溯性和导览表达的自然性。具体而言，本文希望实现以下目标。

第一，构建可扩展的文物知识库。系统需要将文物相关资料组织为可检索、可维护的知识条目，为后续问答生成提供事实依据。第二，实现基于 RAG 的文物问答链路，使模型回答尽量基于知识库内容，而不是完全依赖模型参数记忆。第三，实现图像输入场景下的文物识别与问答，使用户在不知道文物名称时也能通过拍照提问。第四，对比可解释的“图像检索+文本 RAG”方案和端到端多模态大模型方案，分析二者在准确性、稳定性和工程可控性方面的差异。第五，集成语音合成与网页界面，使系统具备可演示、可体验的导览助手形态。

本研究具有以下意义。应用层面，系统可用于博物馆智能导览、文物知识问答和文化传播场景，能够降低固定讲解内容的维护成本，提高参观者获取知识的效率。技术层面，本文探索大语言模型、多模态模型、图像检索、文本检索和 TTS 在垂直领域中的组合方式，为文化遗产场景下的大模型应用提供工程实践。研究层面，本文同时保留方案 A 与方案 B 两条技术路线，并通过统一评测集进行对照实验，使结论不局限于单一模型或单一链路，而能围绕“可解释流水线”和“端到端多模态模型”展开更具体的讨论。

1.3 相关研究

1.3.1 智慧博物馆与数字文化遗产

智慧博物馆强调利用数字技术提升藏品管理、文化传播和观众服务能力。早期研究从物联网和移动服务角度讨论智能博物馆设计，指出展馆空间可以通过感知设备、移动终端和服务系统形成更具交互性的文化环境[1]。国内研究也从博物馆数字化转型、数字人文建设和元宇宙展示等角度讨论智慧博物馆的发展路径[2-4]。这些研究表明，博物馆智能服务不应仅停留在信息展示层面，而应围绕观众理解、知识组织和交互体验展开。

数字文化遗产展示技术的发展进一步拓展了导览系统的形态。AR、VR 和 MR 等技术已经被用于文化遗产教育、虚拟复原、沉浸式展示和交互探索[5]。相比这些强调空间体验和视觉展示的技术，本文更关注面向文物知识问答的智能导览。也就是说，系统不仅需要“看见文物”，还需要“讲清文物”，并在回答中保持事实准确和表达自然。

1.3.2 检索增强生成与领域问答

大语言模型具有较强的语言理解和生成能力，但在垂直领域问答中容易受到参数知识过时、事实幻觉和来源不可追溯等问题影响。检索增强生成通过在生成前引入外部知识检索，使模型能够基于检索证据回答问题[7]。在知识密集型任务中，这种方式能够增强回答的事实性，也便于系统维护知识库内容。

本文的文物导览任务具有典型的知识密集特征。用户问题可能涉及展品名称、时代、材质、馆藏单位、功能用途、历史背景和文化价值等多种字段。若仅依赖大模型内部知识，回答可能泛化、遗漏或编造。采用 RAG 后，系统可以将文物知识库作为外部事实来源，先召回相关条目，再引导模型生成讲解，从而提高回答的可控性。

1.3.3 向量检索与图像检索

文本向量表示能够将自然语言问题和文档映射到统一语义空间，使同义表达和近义问题能够通过相似度进行匹配。Sentence-BERT 通过句向量建模提升了语义检索效率[8]。FAISS 提供了高效的向量相似度搜索能力，适合在大量文本或图像向量中进行近邻检索[9]。本文使用文本向量索引完成文物知识召回，并使用图像向量索引完成候选文物识别。

图像检索部分采用 CLIP 作为图文对齐基础。CLIP 通过大规模图文对比学习获得统一语义表示，可用于图像分类、图文检索和零样本识别[10]。在本文方案 A 中，CLIP 并不直接生成答案，而是用于将用户上传图片映射到相似文物图片，从而获得候选文物名称。随后，候选文物名称与用户问题共同进入文本 RAG 链路。这样的设计使图像识别与文本生成相互解耦，便于分析错误来源。

1.3.4 多模态大模型与视觉问答

多模态大模型能够同时处理图像和文本输入，并生成自然语言回答。视觉指令微调方法将视觉编码器与大语言模型连接，使模型获得图像描述、视觉问答和多模态对话能力[11]。Qwen2.5-VL 等模型进一步增强了视觉识别、文档理解和多模态推理能力[12]。这类模型为“拍照提问”式导览提供了更直接的实现路径。

然而，端到端多模态问答并不天然等价于可靠的文物导览。文物图像往往存在细粒度差异，且很多专业信息无法仅从图像中判断。例如馆藏单位、具体

年代和文化背景通常需要外部资料支持。因此，本文将多模态大模型作为方案 B 进行对照实验，并额外设置 grounded 模式，考察检索上下文对多模态模型回答质量的提升作用。

1.3.5 语音合成与生成质量评价

文本转语音技术用于将系统生成的讲解文本转化为语音输出。Tacotron 2 和 FastSpeech 2 等神经语音合成方法从自然度和推理效率等方面推动了 TTS 技术发展[13][14]。本文接入 TTS 模块，使系统能够形成面向观众的语音导览体验，而不是仅提供文本问答。

在生成质量评价方面，BLEU 和 ROUGE 等指标常用于机器翻译和摘要任务[15][16]，能够反映生成文本与参考答案之间的词面重合程度。BERTScore 等语义评价方法进一步关注语义相似度[17]，CLIPScore 则可用于图像描述与图像内容之间的相关性评价[18]。不过，文物导览回答既要求事实准确，也要求表达自然、适合面向观众讲解。因此，本文在传统文本指标之外，引入语义裁判和导览质量裁判，从事实性、有据性、完整性、清晰度、导览风格和吸引力等维度评价生成结果。

1.4 本文的主要研究内容

本文围绕基于多模态大模型的语音导览助手展开研究，主要内容包括以下六个方面。

第一，构建文物领域知识库。本文整理文物公开资料，形成包含展品名称、所属时代、类别、馆藏单位、材质、功能用途、文化价值、历史背景等字段的半结构化知识库。知识库既保留自然语言描述，又通过字段标签增强可解析性，为后续检索和生成提供基础。

第二，设计并实现文本 RAG 问答链路。系统采用文本嵌入模型将知识条目转换为向量表示，使用 FAISS 构建向量索引，根据用户问题召回相关文物资料，并结合提示词模板约束大语言模型生成回答。

第三，设计图像检索增强式多模态方案。方案 A 采用 CLIP 图像嵌入和 FAISS 图像索引识别候选文物，再将识别结果与用户问题结合，进入文本 RAG 链路生成回答。该方案具有较强可解释性，便于分析错误来源。

第四，设计端到端多模态大模型对照方案。方案 B 直接将用户图像和问题输入多模态大模型，并设置直接模式和知识库增强模式。直接模式用于观察模型自身视觉问答能力，知识库增强模式用于考察检索上下文对回答质量的提

升。

第五，实现语音播报和交互界面。系统通过 TTS 模块将生成回答转换为语音输出，并基于 Streamlit 实现网页交互界面，同时保留命令行问答入口，便于演示、调试和评测。

第六，构建离线评测流程。本文实现多组评测脚本，对文本 RAG、方案 A 和方案 B 进行离线测试，并记录检索命中、回答正确性、语义相似度和模型裁判得分等指标。

第 2 章　方法框架

2.1 总体框架

本文系统采用“离线资源构建 + 在线问答推理”的总体框架。离线阶段完成知识库整理、文本向量索引构建和图像向量索引构建；在线阶段根据用户输入类型选择不同问答路径。若用户只输入文本问题，系统直接进入文本 RAG 链路；若用户上传文物图片，系统先进行图像候选检索，再进入方案 A 或方案 B。

系统的核心思路不是让大模型孤立回答，而是让模型在可检索知识和可追踪候选结果的约束下完成讲解生成。对于文本问题，检索模块提供相关文物资料；对于图像问题，图像检索模块提供候选文物；对于生成回答，提示词模块要求模型优先依据资料回答，并在资料不足时拒绝编造。该框架兼顾了大模型的自然语言表达能力和知识库的事实约束能力。

2.2 文本 RAG 问答方法

文本 RAG 是系统的基础问答链路。系统首先将文物知识库中的每个条目编码为文本向量，并写入 FAISS 索引。用户输入问题后，问题同样被编码为向量，与索引中的文物条目进行相似度匹配，召回 Top-K 相关内容。召回结果经过阈值和候选差距过滤后，被拼接为提示词中的“参考资料”部分。大语言模型根据用户问题和参考资料生成回答。

该流程的关键在于检索与提示词约束。检索决定模型可以获得哪些事实材料，提示词决定模型如何使用材料。本文在提示词中明确要求回答应基于参考资料，不能凭空编造；当资料不足时，应说明无法确定。对于导览场景，提示词还要求语言自然、清晰，并具有一定讲解感。

2.3 方案 A：图像检索增强式问答

方案 A 面向用户上传文物图片的场景。其基本流程为：用户上传图片后，系统使用 CLIP 图像编码器生成图片向量，并在文物图片索引中检索相似图片。若 Top1 候选得分达到最低阈值，且与 Top2 候选之间存在足够差距，则认为该候选文物具有较高置信度。随后，系统将候选文物名称与用户问题合并构造文本查询，进入文本 RAG 链路并生成最终回答。

方案 A 的优势是可解释性较强。系统可以记录图像检索候选、相似度分数、文本检索上下文和最终回答。当回答错误时，可以判断错误发生在图像检索、文本检索还是模型生成阶段。对于文物导览场景，这种可追踪性具有重要意义，因为系统主动拒绝不确定识别通常比给出错误讲解更安全。

2.4 方案 B：多模态大模型问答

方案 B 用于检验端到端多模态大模型在文物导览任务中的能力。direct 模式直接将用户图片和问题输入多模态大模型，由模型根据图像内容和自身知识生成回答。该模式流程最短，交互形式最自然，但缺少外部知识约束。

grounded 模式在 direct 模式基础上加入检索上下文。系统仍先通过图像检索获得候选文物，再通过文本检索召回相关资料，然后将图片、问题和资料一起输入多模态大模型。该模式试图结合多模态模型的视觉理解能力和知识库的事实约束能力。

本文将方案 A 作为默认可解释导览路线，将方案 B 作为实验对照路线。两种方案的比较并不是为了简单判断“哪一个模型更强”，而是分析在文物导览任务中，图像检索、文本检索和多模态生成各自承担什么作用。

第 3 章　系统构建

3.1 文物知识库构建

文物知识库是系统事实可靠性的基础。本文将文物资料整理为半结构化文本，每条记录包含展品名称、所属时代、类别、馆藏单位、材质、功能用途、文化价值、历史背景和故事讲解等字段。这样的组织方式既保留了自然语言讲解所需的叙述信息，也便于评测时根据字段构造标准问答。

知识库构建过程包括资料清洗、字段规范化和统一文件生成。系统通过脚本将不同来源的文物资料合并为统一知识库文件，并在后续构建文本索引时逐条读取。对于导览系统而言，知识库质量直接影响最终回答质量。若知识库信息缺失或表达不一致，即使检索和生成模型表现良好，也可能产生不完整或不准确的回答。

3.2 文本索引与图像索引构建

文本索引构建时，系统读取统一知识库，将每条文物记录编码为文本向量，并使用 FAISS 建立相似度检索索引。在线问答时，用户问题被编码后与索引向量进行匹配，系统返回若干候选文物资料及相似度分数。

图像索引构建时，系统读取文物图片及元数据，使用 CLIP 图像编码器生成图像向量，并建立图像 FAISS 索引。每个图像向量对应文物名称、图片路径和来源信息。用户上传图片后，系统通过图像索引返回相似图片和候选文物名称。为了降低误识别风险，本文设置了最低相似度阈值和候选差距阈值。当候选结果不够稳定时，系统不强行给出文物名称。

3.3 提示词与模型调用

提示词是连接检索结果和大模型生成的重要环节。本文根据不同任务设计了多套提示词：文本 RAG 提示词强调基于资料回答和资料不足时拒答；方案 A 提示词强调候选文物与检索资料的一致性；方案 B direct 提示词用于直接视觉问答；方案 B grounded 提示词则要求模型综合图片、问题和检索资料作答。

模型调用模块支持本地模型和云端模型。文本生成可调用文本大语言模型，方案 B 可调用本地部署的多模态大模型。为了便于对比实验，系统支持分别

配置方案 A 和方案 B 使用的模型。这样的设计避免了不同方案在模型能力和输入形式上的混淆，也便于后续更换模型进行实验。

3.4 语音输出与交互界面

系统在回答生成后调用 TTS 模块，将文本讲解转换为音频文件，并在交互界面中提供播放入口。网页端使用 Streamlit 实现，用户可以输入文本问题，也可以上传文物图片并选择不同问答方案。界面展示回答结果、候选文物和部分检索信息，便于调试和演示。

从导览应用角度看，语音输出并不是简单附加功能，而是系统从“问答程序”走向“导览助手”的关键环节。用户在参观场景中更倾向于听取讲解，而不是阅读长文本。因此，生成内容不仅要准确，也要清晰、连贯、适合口语化播报。

3.5 离线评测流程

为了系统性比较不同方案，本文实现了离线评测脚本。方案 A 评测记录图像是否命中、候选是否可信、文本上下文是否找到以及最终回答是否正确。方案 B 评测分别运行 direct 和 grounded 模式，并记录自动准确率、语义裁判结果和文本生成指标。生成答案后，系统还可以通过独立裁判脚本对回答进行语义正确性和导览质量评价。

离线评测的设计使系统分析不依赖单个演示样例，而是可以在全量测试集上获得统计结果。对于毕业设计而言，这种评测方式能够更清晰地说明不同技术路线的优劣。

第 4 章　实验与结果分析

4.1 实验设置

实验在本地开发环境和远程 GPU 环境中完成。本地环境用于知识库构建、索引构建和结果分析，远程 GPU 环境用于运行多模态大模型批量评测。方案 A 使用 CLIP 图像嵌入模型完成图像检索，使用文本大语言模型完成回答生成；方案 B 使用本地部署的 Qwen2.5-VL 多模态模型完成图像问答。

测试集包含 199 个文物图像样本和 1592 个问答样本。方案 A 在该测试集上运行一次；方案 B 分别运行 direct 和 grounded 两种模式，因此总结果行数为 3184。表 4-1 给出了实验数据规模。

表 4-1　测试集规模与评测设置

评测对象	图像样本数	问答样本数	运行模式	结果行数
方案 A	199	1592	图像检索 + 文本 RAG	1592
方案 B direct	199	1592	多模态模型直接问答	1592
方案 B grounded	199	1592	多模态模型 + 检索上下文	1592

4.2 评价指标

本文从四类指标评价系统效果。第一类是检索与识别指标，包括图像检索是否找到候选、候选是否达到置信阈值、识别名称是否正确以及文本上下文是否找到。第二类是问答正确性指标，包括自动准确率、平均自动得分和语义裁判通过率。第三类是文本生成指标，包括 ROUGE-L、BLEU-1/2/4 和语义相似度，用于衡量生成回答与参考答案之间的重合程度和语义接近程度。第四类是导览质量指标，由裁判模型从事实性、有据性、导览风格、清晰度、完整性、流畅度、吸引力和综合质量等维度评分。

需要说明的是，BLEU 和 ROUGE 对中文开放式讲解文本并不完全友好。短字段答案若被模型扩展为自然语言解释，词面重合度可能下降。因此，本文

不将单一指标作为唯一结论，而是结合自动准确率、语义相似度和导览质量裁判进行综合分析。

4.3 方案 A 实验结果

方案 A 的主要结果如表 4-2 所示。可以看到，方案 A 在图像检索阶段表现稳定，图像找到率达到 1.000，图像置信率达到 0.985，识别名称准确率达到 1.000。文本上下文找到率同样为 0.985，说明在多数样本中，图像候选能够顺利连接到文本知识库。事实答案准确率达到 0.964，说明方案 A 的检索链路能够较好支撑字段型文物问答。LLM 回答准确率为 0.609，低于事实答案准确率，主要原因是生成模型在短字段问题上可能输出解释性语句，导致自动匹配更严格。

表 4-2 方案 A 图像识别与问答结果

指标	数值
图像样本数	199
问答样本数	1592
图像找到率	1.000
图像置信率	0.985
识别名称准确率	1.000
文本上下文找到率	0.985
事实答案准确率	0.964
LLM 回答准确率	0.609

进一步观察文本生成指标，方案 A 的整体 ROUGE-L F1 为 0.1949，BLEU-4 为 0.1027，语义相似度为 0.6137。分字段结果显示，历史背景、文化价值和功能用途等长文本字段语义相似度较高，分别达到 0.7796、0.7335 和 0.7211；所属时代等短字段语义相似度较低。这说明模型更适合生成解释性讲解，对格式严格的短答案仍需进一步约束。

表 4-3 方案 A 文本生成指标

字段	ROUGE-L F1	BLEU-1	BLEU-2	BLEU-4	语义相似度

展品名称	0.1817	0.1235	0.1151	0.0970	0.6008
所属时代	0.0810	0.0631	0.0526	0.0423	0.2838
类别	0.1522	0.1112	0.0971	0.0697	0.6374
馆藏单位	0.3336	0.2434	0.2346	0.2151	0.5765
材质	0.0385	0.0351	0.0263	0.0214	0.5771
功能用途	0.2611	0.1689	0.1487	0.1160	0.7211
文化价值	0.2418	0.1544	0.1449	0.1266	0.7335
历史背景	0.2694	0.1851	0.1658	0.1338	0.7796
整体平均	0.1949	0.1356	0.1231	0.1027	0.6137

总体来看，方案 A 的优势在于识别链路稳定、错误来源可拆分、回答依据清晰，适合作为当前系统的默认导览方案。其不足主要体现在生成模型对短字段答案的格式控制不够严格，以及导览表达的吸引力仍有提升空间。

4.4 方案 B 实验结果

方案 B 的 direct 与 grounded 模式结果差异明显。direct 模式在 1592 条样本上的自动准确率仅为 0.107，平均自动得分为 0.209，语义裁判通过率为 0.119。该结果表明，在没有外部知识库辅助时，多模态大模型难以稳定识别具体文物并回答专业字段问题。

grounded 模式显著改善了回答效果。加入图像检索和文本检索上下文后，自动准确率提升至 0.804，平均自动得分为 0.864，语义裁判通过率达到 0.876。图像置信率和文本上下文找到率均为 0.985，说明 grounded 模式的主要提升来自外部知识 grounding，而不是模型单独完成识别和事实推理。

表 4-4 方案 B direct 与 grounded 模式问答结果

指标	direct 模式	grounded 模式
结果行数	1592	1592
自动准确率	0.107	0.804
平均自动得分	0.209	0.864
目标文物名称提及率	0.011	0.617

参考答案提及率	0.106	0.628
图像置信率	-	0.985
文本上下文找到率	-	0.985
语义裁判通过率	0.119	0.876
平均语义裁判分数	0.455	0.904

文本生成指标也呈现相同趋势。grounded 模式的语义相似度为 0.6430，明显高于 direct 模式的 0.2610；ROUGE-L 和 BLEU 指标也有明显提升。该结果说明，外部检索上下文不仅提高了回答事实性，也改善了生成内容与参考答案之间的语义接近程度。

表 4-5 方案 B direct 与 grounded 模式文本生成指标

模式	ROUGE-L F1	BLEU-1	BLEU-2	BLEU-4	语义相似度
direct 模式	0.0398	0.0709	0.0541	0.0466	0.2610
grounded 模式	0.2786	0.2099	0.1927	0.1681	0.6430

4.5 导览讲解质量评价

除问答正确性外，导览系统还需要回答“讲得是否像导览员”的问题。本文进一步使用导览质量裁判对方案 A、方案 B direct 和方案 B grounded 的回答进行评分。裁判维度包括事实性、有据性、导览风格、清晰度、完整性、流畅度、吸引力和综合评分。

表 4-6 导览讲解质量裁判结果

评测对象	有效评分数	通过率	事实性	有据性	导览风格	清晰度	完整性	流畅度	吸引力	综合评分
方案 A	1563	0.955	4.118	4.782	3.501	4.485	4.121	5.000	2.950	3.963
方案 B direct	1577	0.156	2.385	3.160	2.221	2.530	1.826	4.839	2.036	2.592
方案 B grounded	1568	0.843	4.176	4.635	3.345	4.325	4.137	4.987	2.737	3.822

从表 4-6 可以看出，三种设置的流畅度都较高，说明当前大模型普遍具备较好的中文表达能力。但事实性、有据性、完整性和导览风格差异明显。方案 A 的通过率最高，达到 0.955，综合评分为 3.963；方案 B grounded 接近方案 A，通过率为 0.843，综合评分为 3.822；方案 B direct 明显较弱，通过率仅为 0.156。该结果再次说明，文物导览的关键并不是让模型“说得流畅”，而是让模型“说得准确、说得有依据、说得像导览”。

4.6 综合对比与误差分析

综合各项实验结果，方案 A 更适合作为当前系统的默认路线。它在图像识别、事实准确性和导览质量上表现稳定，并且能够追踪错误来源。方案 B direct 虽然流程简单，但在专业文物问答中表现不足。方案 B grounded 在加入检索上下文后明显提升，说明多模态大模型并非不能用于导览任务，而是需要与知识库检索结合使用。

表 4-7 主要方案综合对比

对比维度	方案 A	方案 B direct	方案 B grounded
是否使用图像检索	是	否	是
是否使用文本知识库上下文	是	否	是
图像/上下文置信率	0.985	-	0.985
识别名称准确率	1.000	-	-
自动准确率/LLM 准确率	0.609	0.107	0.804
语义裁判通过率	-	0.119	0.876
导览质量通过率	0.955	0.156	0.843
语义相似度	0.6137	0.2610	0.6430
导览综合评分	3.9635	2.5929	3.8221
可解释性	高	低	中
推理资源需求	较低	较高	较高

误差主要来自三个方面。第一，少量图像候选相似度过于接近，系统会触发低置信拒答。该现象虽然降低了覆盖率，但有助于避免错误讲解。第二，短

字段问答容易受到自动指标影响。例如所属时代和材质等字段参考答案较短，模型若输出扩展解释，词面匹配分数可能偏低。第三，方案 B direct 容易产生泛化回答，无法稳定给出具体文物名称和字段事实。这说明在文物导览任务中，外部知识库和置信度控制仍不可替代。

结　论

本文面向博物馆文物语音导览问答场景，对检索增强生成、多模态图像理解和语音输出相结合的智能导览方法进行了研究，并实现了相应的原型系统。针对文物导览任务中专业知识密集、事实准确性要求高、用户输入形式多样等特点，本文构建了包含文物基础信息、历史背景和文化价值的知识库，设计了文本 RAG 问答链路，并在此基础上分别实现了图像检索增强式方案 A 和多模态大模型方案 B。实验结果表明，单纯依赖多模态大模型直接回答专业文物问题时，模型容易给出泛化表述或错误判断；引入外部知识检索和 grounding 约束后，系统在答案正确性、语义相似度和讲解质量方面均有明显提升。总体来看，方案 A 具有较强的稳定性、可解释性和工程可控性，更适合作为当前文物导览系统的默认技术路线；方案 B grounded 则体现出多模态大模型在自然交互和图像问答中的潜力。

本论文的主要工作及结论归纳如下：

1. 构建了面向文物导览任务的半结构化知识库，并建立了基于向量检索的文本 RAG 问答链路。该链路将文物名称、时代、类别、馆藏单位、材质、功能用途、文化价值和历史背景等信息组织为可检索文本，使大模型回答能够受到外部知识约束。实验结果说明，文物导览属于典型知识密集型任务，外部知识库是提升回答可靠性和降低幻觉风险的关键基础。

2. 提出了图像检索增强式文物问答方案 A。该方案利用图像编码模型和 FAISS 索引对用户上传图片进行相似度检索，先识别候选文物，再将识别结果与用户问题共同输入文本 RAG 链路生成讲解。实验表明，方案 A 在当前测试集上取得了较高的图像识别稳定性和事实问答准确率，能够较好解决观众“不知道文物名称但可以拍照提问”的实际导览入口问题。

3. 构建了多模态大模型问答方案 B，并对 direct 和 grounded 两种模式进行了对比实验。结果表明，direct 模式虽然交互链路更短，但在专业文物问答中难以稳定给出具体文物名称和准确字段事实；grounded 模式通过引入检索上下文显著提高了回答质量。这说明端到端多模态大模型并不能天然替代知识库，在文化遗产导览这类高事实性任务中，多模态理解能力需要与外部知识检索机制结合使用。

4. 建立了包含规则指标、文本生成指标和大模型裁判指标的多层次评测流程。除识别准确率、命中率、拒答正确性等任务指标外，本文还引入 ROUGE-L、

BLEU、语义相似度以及面向导览讲解质量的大模型评分，从事实性、完整性、清晰度、流畅性和讲解风格等角度综合评价系统输出。实验结果表明，仅依赖词面重合指标难以全面反映中文导览讲解质量，将语义评价和讲解质量评价结合起来更符合文物导览场景的实际需求。

5. 实现了一个集文本问答、图像问答、知识检索、答案生成、语音输出和网页交互于一体的文物语音导览原型系统。系统支持文本提问和图片提问两种使用方式，并能够在回答过程中保留检索证据和候选文物信息，便于后续分析错误来源。该系统验证了“图像识别入口 + 知识库 grounding + 大模型讲解生成 + 语音播报”技术路线在博物馆智能导览任务中的可行性。

参考文献

[1] CHIANESE A, PICCIALLI F. Designing a Smart Museum: When Cultural Heritage Joins IoT[C]//2014 Eighth International Conference on Next Generation Mobile Apps, Services and Technologies. IEEE, 2014: 300-306. DOI: 10.1109/NGMAST.2014.21.

[2] 秦新华. 智慧博物馆建设的思考[J]. 办公室业务, 2015(01): 55-56. DOI: 10.3969/j.issn.1004-647X.2015.01.046.

[3] 刘健. 智慧博物馆发展中的数字人文建设：以上海博物馆的实践为例[J]. 数字人文研究, 2022, 2(01): 13-21.

[4] 耿国华, 李康. 元宇宙下的智慧博物馆研究进展[J]. 中国图象图形学报, 2023, 28(10): 3140-3162. DOI: 10.11834/jig.220962.

[5] BEKELE M K, PIERDICCA R, FRONTONI E, MALINVERNI E S, GAIN J. A Survey of Augmented, Virtual, and Mixed Reality for Cultural Heritage[J]. Journal on Computing and Cultural Heritage, 2018, 11(2): 1-36. DOI: 10.1145/3145534.

[6] VASWANI A, SHAZEER N, PARMAR N, USZKOREIT J, JONES L, GOMEZ A N, KAISER L, POLOSUKHIN I. Attention Is All You Need[C]//Advances in Neural Information Processing Systems. 2017.

[7] LEWIS P, PEREZ E, PIKTUS A, PETRONI F, KARPUKHIN V, GOYAL N, KÜTTLER H, LEWIS M, YIH W, ROCKTÄSCHEL T, RIEDEL S, KIELA D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. 2020.

[8] REIMERS N, GUREVYCH I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing. 2019.

[9] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535-547. DOI: 10.1109/TBDATA.2019.2921572.

[10] RADFORD A, KIM J W, HALLACY C, RAMESH A, GOH G, AGARWAL S, SASTRY G, ASKELL A, MISHKIN P, CLARK J, KRUEGER G, SUTSKEVER I. Learning Transferable Visual Models From Natural Language Supervision[C]//International Conference on Machine Learning. 2021: 8748-8763.

[11] LIU H, LI C, WU Q, LEE Y J. Visual Instruction Tuning[C]//Advances in Neural Information Processing Systems. 2023.

[12] BAI S, CHEN K, LIU X, WANG J, GE W, SONG S, DANG K, WANG P, WANG S, TANG J, et al. Qwen2.5-VL Technical Report[EB/OL]. arXiv preprint arXiv:2502.13923, 2025.

[13] SHEN J, PANG R, WEISS R J, SCHUSTER M, JAITLY N, YANG Z, CHEN Z, ZHANG Y, WANG Y, SKERRY-RYAN R J, et al. Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. 2018. DOI: 10.1109/ICASSP.2018.8461368.

[14] REN Y, HU C, TAN X, QIN T, ZHAO S, ZHAO Z, LIU T Y. FastSpeech 2: Fast and High-Quality End-to-End Text to Speech[C]//International Conference on Learning Representations. 2021.

[15] PAPINENI K, ROUKOS S, WARD T, ZHU W J. BLEU: a Method for Automatic Evaluation of Machine Translation[C]//Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics. 2002: 311-318. DOI: 10.3115/1073083.1073135.

[16] LIN C Y. ROUGE: A Package for Automatic Evaluation of Summaries[C]//Text Summarization Branches Out. Association for Computational Linguistics, 2004: 74-81.

[17] ZHANG T, KISHORE V, WU F, WEINBERGER K Q, ARTZI Y. BERTScore: Evaluating Text Generation with BERT[C]//International Conference on Learning Representations. 2020.

[18] HESSEL J, HOLTZMAN A, FORBES M, LE BRAS R, CHOI Y. CLIPScore: A Reference-free Evaluation Metric for Image Captioning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 7514-7528. DOI: 10.18653/v1/2021.emnlp-main.595.

哈尔滨工业大学本科毕业论文（设计）
原创性声明和使用权限

本科毕业论文（设计）原创性声明

本人郑重声明：此处所提交的本科毕业论文（设计）《基于多模态大模型的语音导览助手》，是本人在导师指导下，在哈尔滨工业大学攻读学士学位期间独立进行研究工作所取得的成果，且毕业论文（设计）中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本毕业论文（设计）的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本毕业论文（设计）对使用 AI 工具的情况进行了明确标注。

作者签名：　　日期：　　年　　月　　日

本科毕业论文（设计）使用权限

本科毕业论文（设计）是本科生在哈尔滨工业大学攻读学士学位期间完成的成果，知识产权归属哈尔滨工业大学。本科毕业论文（设计）的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存本科生上交的毕业论文（设计），并向有关部门报送本科毕业论文（设计）；（2）根据需要，学校可以将本科毕业论文（设计）部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）本科生毕业后发表与此毕业论文（设计）研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉本科毕业论文（设计）的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

衷心感谢导师韩亮教授对本人的精心指导。他的言传身教将使我终身受益。感谢韩亮教授，以及实验室全体老师和同窗们的热情帮助和支持！