电工技术学报
Transactions of China Electrotechnical Society
ISSN 1000-6753,CN 11-2188/TM

《电工技术学报》网络首发论文

题目：　基于大语言模型的电力领域知识问答方法
作者：　杨燕，刘豪，宋杰，吴裔
DOI：　10.19595/j.cnki.1000-6753.tces.251675
收稿日期：　2025-09-28
网络首发日期：　2026-03-16
引用格式：　杨燕，刘豪，宋杰，吴裔. 基于大语言模型的电力领域知识问答方法[J/OL]. 电工技术学报. https://doi.org/10.19595/j.cnki.1000-6753.tces.251675

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-03-16 11:48:58　网络首发地址：https://link.cnki.net/urlid/11.2188.TM.20260314.0913.001

电工技术学报
TRANSACTIONS OF CHINA ELECTROTECHNICAL SOCIETY

DOI: 10.19595/j.cnki.1000-6753.tces.251675

基于大语言模型的电力领域知识问答方法

杨　燕[1,2]　刘　豪[1,2]　宋　杰[3]　吴　裔[3]

（1. 重庆邮电大学计算机科学与技术学院　重庆　400065
2. 计算智能重庆市重点实验室（重庆邮电大学）　重庆　400065
3. 国网上海市电力公司　上海　200122）

摘要　高效、准确地从海量电力领域信息中获取所需知识，是当前电力行业知识管理面临的重大挑战。大语言模型（LLMs）在自然语言理解和生成方面取得突破，为知识问答提供了新途径，但其在电力领域仍存在局限性，难以理解专业概念并容易产生“幻觉”。对此，该文提出一种基于大语言模型的电力领域知识问答方法，通过知识库增强与参数高效微调的双重机制，提升大语言模型在电力领域问答的准确性。首先，提出一种基于检索增强的电力领域知识问答大模型框架，包含离线知识库构建和在线问答推理两部分：离线模块负责对电力知识文档进行知识切分，并将其向量化存储以构建电力领域知识数据库；在线模块接收用户问题后从知识库中获取相关知识作为上下文，为大模型提供外部电力领域知识，缓解其专业知识不足的局限性。其次，提出基于样本增强与低秩矩阵分解（LoRA）微调的电力领域知识问答大模型优化方法，利用大语言模型的上下文理解与语义生成能力，生成电力知识的多样性表示；并且结合 LoRA 微调参数量少、计算成本低的优势，高效更新电力领域知识问答大模型，有效抑制“幻觉”问题。最后，以 Qwen-7B 模型为例，基于电力市场方向的真实问答集进行测试，实验结果表明应用该方法后可将其 BERTScore 指标的 F1 值从 0.679 提升至 0.997，验证了所提方法的有效性。

关键词：大语言模型　电力知识问答　检索增强生成　样本扩充　参数高效微调

中图分类号：TM73；TP39

0　引言

在“双碳”目标引领[1]和新型电力系统建设[2]的背景下，电力系统正经历着深刻的数字化[3]、智能化[4]转型，海量的技术规范、设备手册、规章制度、研究报告等相关知识以指数级速度增长。如何高效、精准地从这些海量信息中获取所需知识，辅助电网人员进行问题定位和高效决策，已成为电力行业知识管理与应用面临的重大挑战。

传统的知识获取方式[5-6]主要基于关键词搜索、数据库查询等方法，这些方法虽然操作方式简单，但是在检索效率、全面性和精准性方面存在显著不足。例如，依赖关键词的精确匹配方式难以深入理解用户的真实意图，导致检索结果与用户需求匹配度差，用户需在大量冗余信息中不断筛选，费时费力、效率低下。近年来，以 Qwen[7]、DeepSeek[8]、BaiChuan[9]、ChatGLM[10]、GPT[11]、BERT[12]等为代表的大语言模型（Large Language Models, LLMs）在自然语言理解和生成方面取得了突破性进展。大语言模型凭借其强大的语义理解、上下文学习和流畅的文本生成能力，在通用领域的知识问答[13]、文本摘要[14]、机器翻译[15]等方面展现出巨大潜力，为构建智能化的电力领域知识问答系统提供了新的技术途径[16]。

大语言模型虽然具备广泛的知识面，但是将其直接应用于电力这一高度专业化的垂直领域，仍存在明显的局限性[17]。它缺乏对电力领域专业知识的深入理解，容易产生“幻觉”问题[18]，生成看似合理但实际上不准确甚至错误的信息。为了提升大语言模型在垂直领域的知识问答性能，现有方法主要分为两类：基于外部知识增强的方法和基于模型自身优化的方法。

在外部知识增强方面，利用检索增强生成（Retrieval-Augmented Generation, RAG）技术[19]，从外部信息源中检索相关信息来增强 LLMs 的能

国家电网有限公司总部科技项目资助（52090025001G-129-ZN）。
收稿日期 2025-09-28　改稿日期 2025-11-29

力，从而提高生成内容的相关性和质量。RAG 相较于微调不需要对模型重新进行训练，仅通过更新外部知识库来适应知识的变化，节省了大量计算资源。目前，RAG 的研究正处于快速发展阶段，主要集中在优化检索环节以提高捕获相关信息的精度和效率。其中，知识切分的质量是影响检索准确性的关键因素，常见的切分策略是将文档按照固定数量的 token（如 100、256、512）进行分割，这种方式难以保证知识块的语义完整性。为解决这一问题，文献[20]使用 Small2Big 模型，从细粒度的文本单元（如句子）开始检索，然后逐步扩大检索范围到更大的文本单元（如文本块）。文献[21]提出了一种元分块框架，该框架一方面识别最优分割点，另一方面保留全局信息，在细粒度和粗粒度文本分块之间取得了平衡。而文献[22]提出了一种不分块的上下文检索方法，将用户查询和长文档直接输入 LLMs，通过预测 token 的概率来识别最相关的段落，但对计算资源的需求更高。此外，也有研究人员对初步检索后获取的大量候选知识进一步精炼，提高输入 LLMs 的上下文质量。文献[23-24]利用交叉编码器（cross-encoders）对初步召回的知识块再次进行相关性评分，将最相关的片段前移。文献[25]通过训练一个小型上下文过滤模型，基于词汇和信息论方法识别有用的上下文，缩短了输入 LLMs 的上下文长度。综上可见，RAG 通过动态引入外部专业知识，能够有效缓解 LLMs 的“幻觉”问题，然而其性能依赖知识切分的语义完整性与被检索出上下文的精确度。因此，如何从版式复杂的电力文档中准确地提取信息，并将其切分为语义完整的知识片段以供检索，是 RAG 在电力领域应用前需要解决的关键问题。

在模型自身优化方面，则通过重新训练模型以适应特定领域，即微调（Fine-Tuning, FT）大语言模型，从参数规模上可以分为全参数微调[26]和参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）[27]。全参数微调的核心思想是通过下游任务数据集来更新 LLMs 的全部或绝大部分参数，这种方法能够最大限度地挖掘模型的潜力，使其深度融合领域知识，在特定任务上达到最优性能[28]。但由于 LLMs 参数量通常高达百亿甚至千亿级别，更新全部参数需要消耗极高的计算资源，且针对不同的下游任务进行微调都需要存储一份完整的模型权重副本，导致存储成本高昂。PEFT 方法通过仅更新或引入少量参数对 LLMs 进行微调，在显著降低计算和存储开销的同时，达到与全参数微调相近的性能。目前，研究人员探索了多种不同的参数高效微调方式，主要包括向模型中插入小型适配器模块[29]、对模型的输入词元添加前缀参数[30]、仅微调部分层[31]以及通过低秩矩阵分解（Low-Rank Adaptation, LoRA）[32]等方法实现参数更新。在众多 PEFT 方法中，LoRA 因其可在保证性能的同时大幅降低计算与存储负担，被广泛应用于多种垂直领域任务[33]。但在电力领域中，其效果因训练样本数量稀缺而受到限制，因此，有必要基于 LoRA 方法进一步探索电力领域知识问答大模型的微调方法。

综上可见，尽管 LLMs 的相关研究已十分丰富，但基于 LLMs 实现电力领域的知识问答[34]仍存在挑战：一是针对电力领域中的标准、规程等非结构化文档，如何进行有效的知识提取和表示，建立电力领域知识库，并与 RAG 机制进行有效融合；二是电力领域高质量问答样本获取成本高、数量少，限制了微调的效果，如何构建高质量的问答微调数据集，并基于 LoRA 方法对大语言模型进行微调。

针对上述挑战，本文提出基于大语言模型的电力领域知识问答方法，通过外部知识库增强与内部参数高效微调的双重机制，有效缓解大语言模型的“幻觉”问题。具体贡献如下：

1）提出了一种基于检索增强的电力领域知识问答大模型框架。该框架首先设计了一种基于大语言模型的电力文本信息自适应提取方法，能够高效地对电力文档进行版面解析并提取其文本信息；其次，依据文档的标题层级结构对其进行递归切分，确保知识块切分的语义完整性，并构建高质量的电力领域知识库；最后，在此基础上，通过设计提示词引导大语言模型充分理解和利用这些电力领域知识，显著提升大语言模型问答的准确性。

2）提出了一种基于样本增强与 LoRA 微调的电力领域知识问答大模型优化方法。该方法首先利用大语言模型强大的文本生成能力对原始问答对样本进行扩充，改变原始文本信息的文字表述而不改变其语义，通过这种方法规模化地扩充训练样本，能够有效解决电力领域问答对数据稀缺的问题；然后，将问题与检索到的相关知识相结合并作为训练样本的输入，构建与检索增强机制实际输入结构一致的样本结构；最后，在基于 LoRA 微调训练大语言模型理解电力领域知识的同时，也增强其利用外部检索信息生成准确回复的能力。

1 基于检索增强的电力领域知识问答大模型框架

本节构建了一个基于检索增强的电力领域知识问答大模型框架，如图 1 所示。该框架通过引入外部电力专业知识库提升大语言模型在电力领域的知识问答效果，将原始的非结构化文档转换为易于检索和理解的知识片段，并存储到向量数据库中，当接收到用户输入的问题后，在知识库中检索出相关知识，协助大语言模型进行推理。

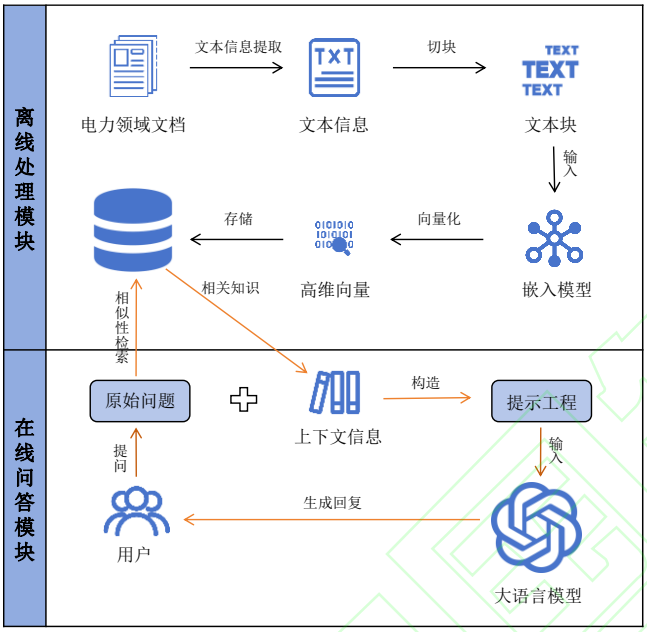

图 1 基于检索增强生成的电力知识问答大模型框架

Fig.1 Power knowledge question-answering LLM framework based on retrieval-augmented generation

1.1 总体框架简介

针对电力领域知识问答对准确性、专业性及可追溯性要求高的特点，本文构建了一个适用于电力领域知识问答的检索增强生成框架（Power Retrieval-Augmented Generation, P-RAG）。该框架由离线处理模块和在线问答模块两部分构成。

离线处理模块首先使用基于大语言模型的自适应文本信息提取方法对相关电力文档进行版面解析与文本信息提取，进而依据文本中的标题层级结构（如章、节、条）进行知识切分，并将切分得到的文本知识块编码为向量，存储到向量数据库中以构建电力领域向量知识库。这一过程旨在将非结构化的电力文档转换为易于检索的知识片段。

在线问答模块接收到用户输入的问题，首先在离线阶段构建的知识库中检索与用户问题最相关的知识块，随后将用户问题与检索到的知识块作为上下文，构造提示词输入大语言模型，大语言模型基于提供的上下文进行推理，输出对用户问题的回复。

该框架的核心在于将外部的电力领域知识与大语言模型强大的自然语言理解和生成能力相结合，有效地应对通用大语言模型在电力领域专业知识不足和易产生“幻觉”的问题。

1.2 离线向量知识库构建

向量知识库是整个知识问答的基础，其质量直接影响在线问答模块的检索精度与生成效果。构建电力领域向量知识库是从原始的非结构化电力领域文档到结构化、可计算的向量表示的转换过程。具体而言，电力领域向量知识库构建包括三个核心环节：首先，采用自适应文本信息提取方法对电力文档进行版面解析与文本信息抽取；其次，基于文档的标题层级结构的知识分块策略，将长篇文本切分为长度适中、语义完整的知识单元；最后，通过文本向量化技术将知识块映射为高维语义向量并存储到向量数据库中，为后续的智能问答任务奠定基础。

1.2.1 自适应文本信息提取方法

电力行业的标准、报告、论文等文档是重要的知识载体，且格式多样，包含大量非结构化文本、公式及特定的版式元素。在处理这些复杂文档时，常面临公式识别困难、冗余信息干扰及跨页内容整合不便等问题。为解决这些挑战，本文借助大语言模型进行自适应文本信息提取，通过设计合理的提示词让大语言模型对文档进行版面解析并提取其文本信息，本文设计了如下提示词：

“你是一个文本信息智能抽取专家，擅长从 PDF 或图像文件中提取核心文本信息并进行规范化处理。请严格按照以下要求对上传的文档进行处理：

1. 准确识别文档每页中的正文、标题、公式、图表注释等有效信息；
2. 自动识别并剔除所有页眉、页脚、页码等非正文内容；
3. 将上下结构的分式公式规范为“分子/分母”格式表示，必要时添加括号以确保表达清晰、准确；
4. 保留文档的核心排版结构，例如标题层级、段落划分等；
5. 将处理后的各页内容按文档原顺序合并，输出为完整的连续文本。

请直接输出结果内容，无需生成额外的解释。”

借助大语言模型进行文本信息提取，能够显著提高文本处理的效率与规范性，从而为后续的知识

分块和向量化奠定了基础。

1.2.2　知识分块

提取出整篇文档的文本信息后，需要将其分割成大小适中、语义完整的知识块，以便于向量化模型高效捕捉其语义信息，并适应大语言模型处理上下文的长度限制。传统的固定长度分块或按段落、句子分块的方法，容易割裂完整的语义单元，影响信息检索精度和问答效果。为此，本节提出基于文档标题层级结构的知识分块策略，流程如图 2 所示。

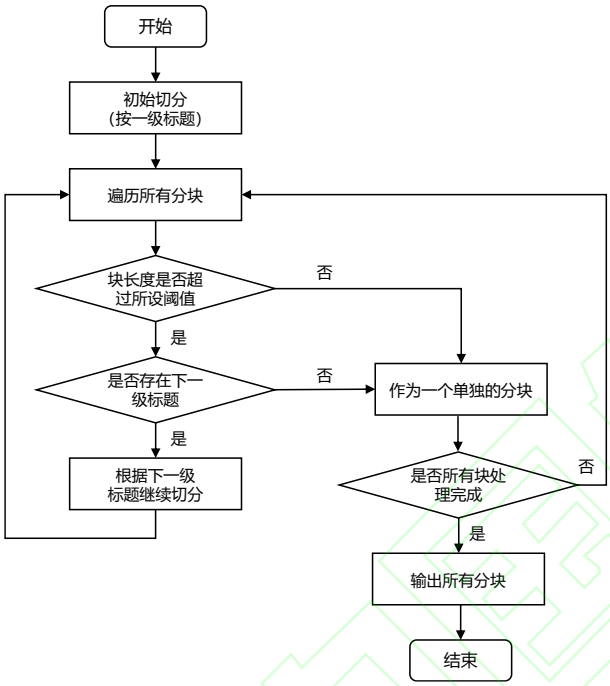

图 2　基于文档标题层级结构的知识分块策略流程

Fig.2　Flowchart of knowledge blocking strategy based on the hierarchical structure of document titles

基于文档标题层级结构的知识分块步骤如下：

1）初始化分块。首先依据文档中的最高层级标题（一级标题如“第 1 章”“1.”等）对整个文档进行初步分割，形成一组粒度较粗的知识块。

2）长度校验。对每个知识块先判断其长度是否超过预设的最大阈值，如果未超过，则该知识块直接纳入最终的分块结果集合，否则进一步切分。

3）递归切分。对步骤 2）中长度超出阈值的知识块，判断其是否存在下级标题，若存在，则依据下级标题将该块细分为更小的子块，并把子块返回步骤 2）进行校验；若不存在，为最大限度地保证其语义完整性，该知识块亦被纳入最终的分块结果集合。

4）输出结果。所有知识块及其子块均处理完毕后，即为最终的知识分块结果集合。

该分块策略的核心优势在于尊重文档原来的结构，避免了跨主题内容的强行切分，生成的知识块语义完整性更好，有利于提升后续向量表示的质量。

1.2.3　向量数据库构建

向量数据库的构建包括文本信息的向量化和存储。向量化是将文本知识块通过向量化模型映射到高维向量空间中以向量表示，语义相近的文本在向量空间中距离更近。考虑到本文处理的电力文本以中文为主，且包含大量专业术语和复杂的句式，因此本文选择 m3e（Moka Massive Mixed Embedding）模型进行知识块向量化。m3e 模型是近年来在中文文本处理任务中表现突出的嵌入模型之一，它通过大规模中文语料上的优化，能够更有效地捕捉中文的细微语义差别。将知识块输入 m3e 模型中计算，即可得到其对应的高维嵌入向量。

本文采用 FAISS（Facebook AI Similarity Search）向量数据库来存储电力知识的向量表示。FAISS 是一个由 Facebook AI 研究院开发的专为稠密向量相似性搜索和聚类的开源数据库，其核心优势在于高效的性能优化：针对大规模向量数据集提供了高度优化的算法实现，即使在十亿级别的向量规模下也能实现 ms 级的检索响应。通过采用 m3e 模型进行文本信息向量化，并利用高性能的 FAISS 库进行存储，最终构建了一个结构化、可高效检索的电力领域知识向量数据库。为后续对用户的查询进行相关信息检索提供了坚实可靠的数据基础。

1.3　在线问答模块

1.3.1　检索策略

在线问答阶段，当用户输入一个问题 Q 时，需要从电力领域向量知识库中快速检索到与之最相关的知识块，本文使用基于向量相似性的搜索方法来实现这一目的。首先，使用 m3e 模型将用户问题 Q 转换为向量 $\boldsymbol{v}_Q$，然后在电力领域向量知识库中执行相似性搜索，找到与 $\boldsymbol{v}_Q$ 相似度分数最高的 Top-K 向量，并返回其对应的文本知识块，本文使用余弦相似度 $S_{\cos}$ 作为量化两个向量 $\boldsymbol{v}_{\mathrm{a}}$ 和 $\boldsymbol{v}_{\mathrm{b}}$ 相似性的标准，即

$$S_{\cos}(\boldsymbol{v}_{\mathrm{a}}, \boldsymbol{v}_{\mathrm{b}}) = \frac{\boldsymbol{v}_{\mathrm{a}} \cdot \boldsymbol{v}_{\mathrm{b}}}{\|\boldsymbol{v}_{\mathrm{a}}\| \|\boldsymbol{v}_{\mathrm{b}}\|} \tag{1}$$

1.3.2　提示工程设计

提示工程是大语言模型执行特定任务的关键技术，其核心在于设计有效的提示词以引导大语言模型生成预期输出。在本文的 P-RAG 框架中，提示工程的作用是将用户问题与检索到的相关电力知识有

效结合，构建提示词输入大语言模型，明确指示模型根据提供的电力知识生成准确回复。本文设计的提示词包含以下关键要素。

1）系统提示词：为大语言模型设定一个特定的“角色”和行为规范。例如，可以设定大语言模型为一个“专业的电力领域知识问答助手”。此外，系统提示词还包含一些强制性的指令，例如，要求模型严格参考提供的上下文信息进行回答，以及如果上下文信息不足以回答问题，要明确指出并停止生成，不要自行编造信息。这些指令能够约束模型行为、减少“幻觉”现象。

2）上下文信息：检索出与用户问题最相关 Top-K 个知识块的集合。为了将其与用户问题进行区分，本文使用特定的标记（如<上下文信息>和</上下文信息>）将其包裹起来。

3）用户问题：用户输入的原始问题查询。同样可以使用标记（如<用户问题>和</用户问题>）将其与上下文信息进行区分。

4）最终指令：通常位于提示词末尾，用于向模型发出最终执行命令，例如，“请根据上面提供的上下文信息，回答用户问题”。

将上述关键要素组合起来，形成输入大语言模型的完整提示词，其基本构造模式如下：

“<系统提示词>
<上下文信息>
[检索到的知识块]
</上下文信息>
<用户问题>
[用户的原始查询]
</用户问题>
<最终指令>”

1.3.3 在线推理

处理用户实时问答请求的流程如下：

1）从电力知识库中检索出与问题向量 $\boldsymbol{v}_Q$ 最相关的 Top-K 个知识片段，按相关性分数排序拼接成上下文 $C=c_1\oplus c_2\oplus\cdots\oplus c_K$，需要注意的是，不是所有的 c_i 都能够帮助模型回复问题，其中有的片段包含问题的正确答案，有的片段只是部分相关且包含冗余信息。

2）将用户问题 Q 和检索知识库得到的相关上下文 C 相结合，构造提示词输入大语言模型。

3）大语言模型要在这部分混杂着有效信息和冗余信息的知识中进行推理，模型需要真正理解问题，过滤无关的干扰内容，辨别出真正能够回答问题的关键信息，然后输出最终回复 Ans。

4）将模型的输出 Ans 返回用户。

2 基于样本增强与 LoRA 微调的电力领域知识问答大模型优化方法

上一节构建的基于检索增强的电力领域知识问答大模型框架能够为大语言模型提供相关的电力领域知识，但模型最终回复的准确性取决于其对电力领域知识的理解深度和从冗余信息中提取关键点的能力。为了进一步提升大语言模型在电力领域知识问答任务上的表现，本节提出基于样本增强与 LoRA 微调的电力领域知识问答大模型优化方法，通过扩充高质量的微调样本集为模型微调提供丰富的训练资源，并构建与检索增强机制实际输入结构一致的样本结构，采用 LoRA 微调方法对大语言模型进行优化，详述如下。

2.1 基于大语言模型的微调样本集扩充方法

微调是提升大语言模型在电力领域表现的关键技术，但是由于电力领域问答对数据稀缺，可用于微调的训练样本数量少，严重制约了微调的效果。为解决该问题，本文提出一种基于大语言模型的微调样本集扩充方法，利用大语言模型强大的文本理解和生成能力，对已有的高质量种子样本进行多样化改写，从而实现微调样本数量的规模化扩充。主要步骤如下。

1）构建高质量种子样本集。首先，通过人工标注的方式从现有的电力领域文档中构造一个规模相对较小的种子样本集 $S_{\text{seed}}=\{s_1, s_2,\cdots, s_m\}$。每个种子样本 s_i 的形式为<问题 Q_i, 标准答案 Ans_i>，标准答案 Ans_i 是对问题 Q_i 的回答。

2）设计利用大语言模型进行样本改写的提示词，引导大语言模型对输入的种子样本进行文本表述的改写，提示词示例如下：

“你是一个专业的样本改写助手，擅长在不改变原始语义的前提下，对问答对样本进行多样化表达的改写。请你完成以下任务：

1 对给定的原样本进行改写；

2 改写后的样本须保持原样本的基本语义不变；

3 改写后的内容长度应与原样本大致相同；

4 请直接输出改写后的样本内容，无需包含说明。

原样本：{人工标注的种子样本}

改写后的样本：”

3）执行批量改写。将种子样本集 S_{seed} 中的每一个样本 s_i 作为输入，结合设计的样本改写提示词，调用大语言模型进行批量处理。

该方法有效地缓解了电力领域微调样本数量少的问题。此外，由于改写过程引入了文字、语序等方面的变化，增强了训练样本的多样性。使得模型在微调过程中能够接触到对同一查询意图的不同表达形式，从而提高了模型对用户查询语言变化的鲁棒性，使其在面对相同问题的不同表述时仍能准确理解语义并做出回答。

对使用 P-RAG 框架的问答方法而言，微调数据集的构造不仅需要包含电力领域知识本身，更重要的是训练模型理解“根据提供的上下文回答问题”这一特定任务。为此，本文采用“输入：问题 Q+检索出的上下文 C，输出：标准答案 Ans”的微调样本构造方式，上下文 C 是从电力领域知识库中根据问题 Q 检索到的相关知识。这种方式保证了微调样本与 P-RAG 框架实际输入结构的一致性，能够训练模型从用户问题及相关知识中提取关键信息并生成准确回复的能力。

2.2 基于 LoRA 对电力领域知识问答大模型微调

通过 2.1 节的方法，本文获得了更丰富的微调样本集，为模型微调奠定了数据基础。考虑到大模型巨大的参数量以及全参数微调所需的高昂成本，本节将采用 LoRA 策略对大模型进行微调，使其更好地适应电力领域的知识问答任务。

LoRA 微调示意图如图 3 所示，其核心思想在于冻结大语言模型的权重矩阵 $\boldsymbol{W}_0\in\mathbb{R}^{d\times k}$，并在其旁边引入两个低秩矩阵 $\boldsymbol{A}\in\mathbb{R}^{d\times r}$ 和 $\boldsymbol{B}\in\mathbb{R}^{r\times k}$ 来模拟微调带来的权重矩阵变化 $\Delta\boldsymbol{W}=\boldsymbol{AB}$。其中，$r$ 是一个远小于 $\min(d, k)$的超参数，d 和 k 是权重矩阵 $\boldsymbol{W}_0$ 的维度。训练时，模型的原始权重矩阵 $\boldsymbol{W}_0$ 保持不变，仅对 LoRA 旁支矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 进行参数更新，为大语言模型注入电力领域知识。

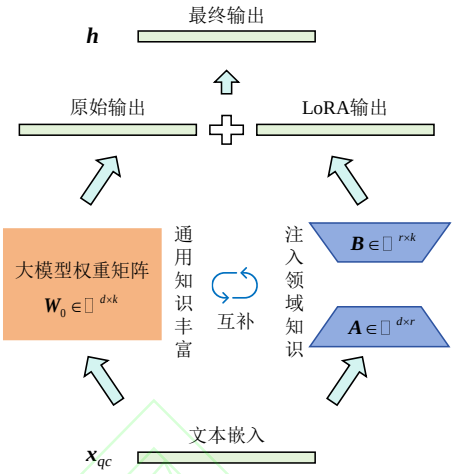

图 3　LoRA 微调示意图

Fig.3　LoRA fine-tuning diagram

以电力领域的问答对作为训练样本，其输入文本被编码为 d 维的向量 $\boldsymbol{x}_{\text{qc}}$，应用 LoRA 后的输出 $\boldsymbol{h}$ 为

$$\boldsymbol{h}=(\boldsymbol{W}_0+\Delta\boldsymbol{W})\boldsymbol{x}_{\text{qc}}=\boldsymbol{W}_0\boldsymbol{x}_{\text{qc}}+\boldsymbol{AB}\boldsymbol{x}_{\text{qc}} \tag{2}$$

由式（2）可以看到，新增了一条计算路径 $\boldsymbol{AB}\boldsymbol{x}_{\text{qc}}$ 与原始路径 $\boldsymbol{W}_0\boldsymbol{x}_{\text{qc}}$ 并行。$\boldsymbol{W}_0\boldsymbol{x}_{\text{qc}}$ 是经过大模型原始权重矩阵得到的输出，$\boldsymbol{AB}\boldsymbol{x}_{\text{qc}}$ 是经过旁支矩阵得到的输出，两者相加得到 LoRA 微调后的最终输出，既保留了大模型自身强大的自然语言理解能力，又引入了在训练中学习到的电力领域知识，实现了通用知识和电力领域知识的互补。

实际中，通常会对 $\boldsymbol{AB}\boldsymbol{x}_{\text{qc}}$ 乘以一个缩放因子 α/r 来平衡 LoRA 路径对原始模型输出的影响，此时应用 LoRA 后的最终输出 $\boldsymbol{h}$ 变为

$$\boldsymbol{h}=\boldsymbol{W}_0\boldsymbol{x}_{\text{qc}}+\frac{\alpha}{r}\boldsymbol{AB}\boldsymbol{x}_{\text{qc}} \tag{3}$$

式中，α 为一个可调节的超参数。

LoRA 微调的目标是使模型预测的答案尽可能地接近真实答案。预测答案与真实答案之间的差异可以通过损失函数来计算，而交叉熵损失函数正是度量模型预测的概率分布与真实分布之间差异的标准方法。对于长度为 T 的答案序列 $Y=\{y_1, y_2,\cdots, y_T\}$，在生成第 t 个词元 y_t 时，其交叉熵损失 L_t 的形式为

$$L_t=-\log\left[p\left(y_t|c,y_{<t}\right)\right] \tag{4}$$

式中，$p(y_t|c, y_{<t})$为模型在给定上下文信息 c 以及已生成的部分答案 $y_{<t}$ 的条件下，预测下一个词元为真实词元 y_t 的概率。所有时间步损失的平均值便是整个答案序列 Y 的总损失 L，表示为

$$L=\frac{1}{T}\sum_{t=1}^{T}L_t=-\frac{1}{T}\sum_{t=1}^{T}\log\left[p\left(y_t|c,y_{<t}\right)\right] \quad (5)$$

式中，L 即为在微调过程中需要最小化的损失函数。在训练过程中，根据该损失函数计算模型预测损失值，并通过反向传播机制更新 LoRA 旁支矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 中的参数。

训练完成后，仅需保存轻量级的 LoRA 适配器权重文件，即可用于后续的在线推理。相比于全参数微调需要更新 $\boldsymbol{W}_0$ 共 $d\times k$ 个参数，LoRA 仅需更新矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的参数，总参数量为$(d+k)\times r$，可极大地降低计算和存储成本。

3 实验分析

3.1 数据集

为验证本文方法的有效性，面向真实电力场景进行查询问答。本文通过收集电力领域相关知识文档，经过人工标注构建高质量电力领域知识问答对。包含规章制度、安全管理、电力设备使用、电力市场等多方面的知识，共计 100 个问答对，主要用作测试集，以衡量不同模型和方法在实际电力问答任务中的表现。此外，为了对模型进行微调，本文根据第 2.1 节提出的基于大语言模型的微调样本集扩充方法构建了 1 016 个微调训练样本。

3.2 评估指标

目前问答任务常见的评估指标包括 EM、BLUE、ROUGE、Precision、Recall、F1 等。其中 BLUE 和 ROUGE 是基于严格的词汇匹配，EM 更是要求完整文本的精确匹配，由于本文问答任务的标准答案均为文本段落，这些指标只考虑词汇层面的一致性，而忽略了文本之间语义层面的一致性。因此，本文采用 BERTScore[35]评估体系，它基于模型生成答案与标准答案的向量表示计算两者之间的相似度分数，优势在于可以有效地处理同义词和句式变换等情况，更适合本文的问答任务。

给定标准答案序列 $ref=\{a_1, a_2,\cdots, a_k\}$和模型生成答案序列 $res=\{\hat{a}_1, \hat{a}_2,\cdots, \hat{a}_l\}$，利用预训练模型 BERT 获得两者的词向量并计算两者之间的语义相似度。BETRScore 主要包含召回率（Recall, R）、精确度（Precision, P）和 F1 值三个指标，表达式分别为

$$R=\frac{\sum_{a\in ref}\max_{\hat{a}\in res}S_{\cos}(a,\ \hat{a})}{|ref|} \quad (6)$$

$$P=\frac{\sum_{\hat{a}\in res}\max_{a\in ref}S_{\cos}(\hat{a},\ a)}{|res|} \quad (7)$$

$$F_1=\frac{2PR}{P+R} \quad (8)$$

式中，$S_{\cos}(a,\ \hat{a})$表示标准答案词元 a 和模型生成答案词元 $\hat{a}$ 的余弦相似度。Recall 计算模型生成答案中每个词元与标准答案中词元的最大相似度之和，并除以标准答案词元的总数。Precision 计算标准答案中每个词元与模型生成答案中词元的最大相似度之和，并除以模型生成答案词元的总数。F1 值是精确度和召回率的调和平均数，它综合了二者的平衡。

3.3 参数设置

本文在 Qwen 系列（包括 Qwen-1.8B 和 Qwen-7B）模型和 ChatGLM3-6B 模型上采用 LoRA 方法进行参数高效微调，详细的训练参数配置见表 1。

表 1 LoRA 微调设置

Tab.1 LoRA fine-tuning configuration

参数名称	设置值
Training Epochs	5
Train Batch Size	2
Gradient Accumulation Steps	8
Max Input Length	2 048
Precision	bf16
Learning Rate	3×10^{-4}
weight_decay	0.1
Warmup Ratio	0.01
LR Scheduler	cosine
LoRA Rank (r)	64
LoRA Scaling Factor (α)	16
Dropout	0.05
LoRA Bias	none

3.4 对比实验

本文中所有实验均在 AutoDL 的云服务器实例上完成测试。具体配置为：vGPU-32 GB*1 卡、Intel(R) Xeon(R) Platinum 8352V CPU @ 2.10 GHz、90 GB 内存。

3.4.1 电力知识大模型问答框架的有效性验证

为验证本文 P-RAG 框架在不同大语言模型上的普遍有效性，本实验对一系列的大语言模型（BaiChuan2-7B、BlueLM-7B、Qwen-7B、ChatGLM3-6B 以及 DeepSeek-R1-Distill-Qwen-7B）进行了对比测试，评估原始模型直接回答问题和结合电力知识

问答框架（P-RAG）回答问题的效果，具体情况见表 2。

表 2　不同大语言模型的问答性能对比

Tab.2　Comparison of question-answering performance among different LLMs

模型名称	P-RAG	BERTScore		
		P	R	F_1
BaiChuan2-7B		0.679	0.693	0.685
	√	**0.910**	**0.880**	**0.894**
BlueLM-7B		0.717	0.681	0.697
	√	**0.920**	**0.823**	**0.866**
ChatGLM3-6B		0.671	0.689	0.679
	√	**0.928**	**0.908**	**0.917**
Qwen-7B		0.702	0.660	0.679
	√	**0.948**	**0.872**	**0.906**
DeepSeek-R1-7B		0.628	0.689	0.656
	√	**0.816**	**0.803**	**0.808**

从表 2 中结果可以看出，所有参评模型结合 P-RAG 框架后都在电力领域知识问答任务上取得了显著提升。以 Qwen-7B 模型为例，使用原始模型进行问答测试时，其 F1 值为 0.679，而结合 P-RAG 后，F1 值大幅提升至 0.906，提升幅度高达约 22.7%，其他模型也展现出类似的趋势。实验结果验证了本文所提基于检索增强的电力领域知识问答大模型框架能够为通用大语言模型赋能，使其在无需进行电力领域微调的情况下，亦可显著提升模型在电力领域知识问答任务上的性能。

3.4.2　P-RAG 框架各模块的有效性验证

为进一步验证所提 P-RAG 框架各模块的有效性，本实验使用结合框架后性能表现最佳的 ChatGLM3-6B 模型，并进行如下实验设置。

1）使用传统 OCR 技术代替本文的自适应文本信息提取方法，记为 OCR。

2）采用固定长度（512 tokens）分块策略替代本文的基于文档标题层级结构的切分策略，记为 $\text{Chunk}_{\text{fixed}}$。

3）简化提示词，去除系统提示词和最终指令，只包含上下文信息和问题，记为 $\text{Prompt}_{\text{simple}}$。

4）本文所提基于检索增强的电力领域知识问答大模型框架，即 P-RAG。

图 4 展示了不同设置下的实验结果，结果表明，将本文所提自适应文本信息提取方法替换为传统 OCR 技术时，F1 值下降 13.7%，说明了高质量文本信息提取对后续处理的重要性。使用固定长度分块策略替代本文基于文档标题层级结构的切分策略时，F1 值下降 11.8%，证明切分知识的语义完整性对于后续检索也至关重要。当简化提示词后，F1 值也下降了 7.4%，这表明本文精心设计的提示词能有效地引导模型利用上下文生成准确回复。

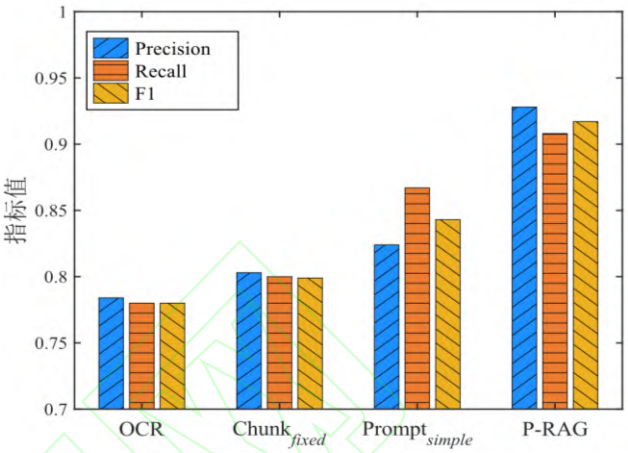

图 4　P-RAG 各模块消融实验

Fig.4　Ablation experiments of each module in P-RAG

3.4.3　大语言模型优化方法的有效性验证

为验证本文所提微调方法的有效性，本实验以 Qwen（Qwen-1.8B 和 Qwen-7B）和 ChatGLM3-6B 模型为基础，对比了以下五种组合的问答性能。

C_1：基础模型，用于参考模型的原始能力。

C_2：使用传统的<问题，标准答案>形式的微调样本，采用 LoRA 方法对基础模型进行微调。

C_3：基础模型结合本文所提 P-RAG 框架。

C_4：C_2 微调后的模型结合 P-RAG 框架。

C_5：本文所提方法，使用<问题+检索出的上下文，标准答案>形式的微调样本，采用 LoRA 方法对基础模型进行微调，并结合 P-RAG 框架。

表 3 展示了不同组合下的问答性能对比。从表 3 中结果可见，C_2 和 C_4 分别是在 C_1 和 C_3 的基础上对模型进行了常规微调，性能均有所下降。本文分析导致这一现象的原因可能是训练样本的输入与实际推理时的输入形式不匹配。常规微调时训练样本的输入仅为“用户问题”，而应用 P-RAG 框架后的实际输入是“用户问题+相关上下文”，与训练时存在冲突。针对此，本文所提方法 C_5 采用符合 P-RAG 框架实际输入结构<问题+上下文，答案>的样本形式对模型进行微调，使问答性能进一步得到提升。

表 3　不同组合方式下的问答性能对比

Tab.3　Comparison of question-answering performance under different combinations

组合方式	模型名称	BERTScore		
		P	R	F_1

C_1	Qwen-1.8B	0.691	0.675	0.682
	Qwen-7B	0.702	0.660	0.679
	ChatGLM3-6B	0.671	0.689	0.679
C_2	Qwen-1.8B	0.658	0.690	0.672
	Qwen-7B	0.670	0.685	0.676
	ChatGLM3-6B	0.662	0.688	0.674
C_3	Qwen-1.8B	0.924	0.832	0.873
	Qwen-7B	0.948	0.872	0.906
	ChatGLM3-6B	0.928	0.908	0.917
C_4	Qwen-1.8B	0.836	0.821	0.826
	Qwen-7B	0.884	0.863	0.871
	ChatGLM3-6B	0.827	0.803	0.813
C_5	Qwen-1.8B	**0.996**	**0.997**	**0.997**
	Qwen-7B	**0.997**	**0.997**	**0.997**
	ChatGLM3-6B	**0.942**	**0.941**	**0.941**

为进一步验证上述实验结果，图 5 中展示了 ChatGLM-6B、Qwen-7B 和 Qwen-1.8B 三个模型在两种微调方法下的损失曲线（实线：本文微调方法 C_5，虚线：常规 LoRA 微调 C_2 和 C_4）。对比同一模型的损失曲线，本文所提 C_5 的损失值始终低于 C_2，证明了本文方法能够有效提升微调效果。在训练耗时方面，两种微调方法下的差异不大，各模型耗时分别约为 3、3、1.5 h，说明本文方法在提升微调性能的同时几乎不增加训练时间成本。对比不同模型在 C_5 下的损失曲线，Qwen-7B 模型的收敛速度最快且最终损失值最低，优于另外两个模型。

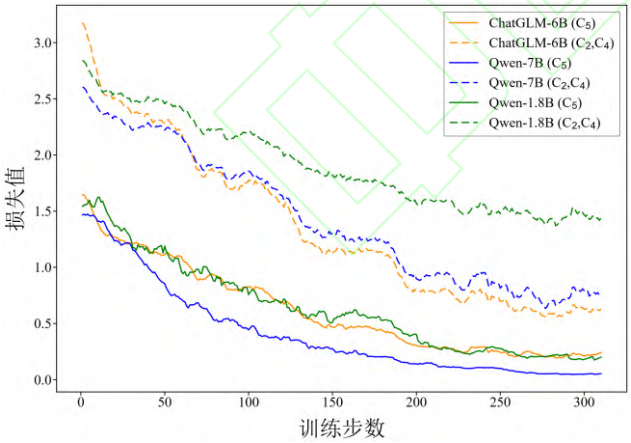

图 5　不同模型微调过程中的损失函数变化曲线

Fig.5　Loss function curves during fine-tuning of different models

3.4.4　样本扩充对微调效果的有效性验证

本实验在相同的超参数配置下，分别使用未经过扩充的原始样本集（412 个样本）和经大语言模型改写扩充后的样本集（1 016 个样本）对 Qwen-7B 模型进行 LoRA 微调，并在相同测试集上进行评估，不同样本规模下的微调效果对比如图 6 所示。可以看到，当训练样本从 412 个增加到 1 016 个时，模型的各项性能指标均有较大提升。其中，F1 值提升了 3.9%，Recall 提升了 5.2%，Precision 提升了 2%，可见采用本文所提样本扩充方法能有效提升模型微调的效果。

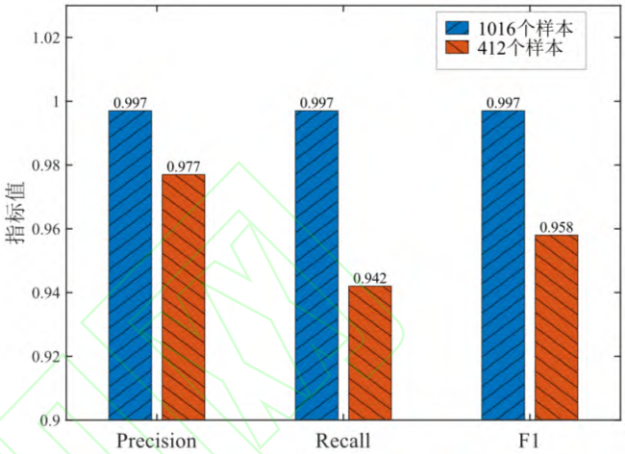

图 6　不同样本规模下的微调效果对比

Fig.6　Comparison of fine-tuning effects under different sample sizes

3.4.5　微调参数量的影响分析

为对比分析不同微调参数量的影响，本文设计如下四种不同参数量的微调设置，实验结果见表 4。

L_1：仅在注意力层的查询、键、值矩阵上应用 LoRA（参数占比约为 0.43%）。

L_2：在 L_1 的基础上，对注意力层的输出投影矩阵应用 LoRA（参数占比约为 1.04%）。

L_3：在 L_2 的基础上，对前馈神经网络的降维层应用 LoRA（参数占比约为 1.43%）。

L_4：在 L_3 的基础上，对前馈神经网络的输出投影矩阵应用 LoRA（参数占比约为 1.82%）。

表 4　不同参数量的微调效果对比

Tab.4　Comparison of fine-tuning effects with different parameter quantities

模型名称	设置	BERTScore		
		P	R	F_1
Qwen-7B	L_1	0.977	0.970	0.973
	L_2	0.979	0.966	0.972
	L_3	**0.997**	**0.997**	**0.997**
	L_4	0.996	0.985	0.990
ChatGLM-6B	L_1	0.910	0.926	0.917
	L_2	0.911	0.931	0.920
	L_3	**0.942**	**0.941**	**0.941**
	L_4	0.935	0.938	0.936

从 L_1 到 L_4 逐步增加了微调参数的规模，由表 4

实验结果显示，当参数量从 L_1 扩大到 L_2 时，模型性能并未显著提升， Qwen 模型的 F1 值甚至出现了微降。当参数量扩大到 L_3 后，Qwen 和 ChatGLM 模型的 F1 值分别上升了 2.5%和 2.4%。当参数规模扩大到 L_4 后，模型性能出现下降，说明不断地增加参数可能会导致过拟合。因此，本文最终采用 L_3 作为微调设置。

3.5 问答案例展示

为了更直观地展示本文所提方法在实际应用中的效果和用户体验，本文基于 Gradio 框架开发了一个“电力领域知识问答系统”。该系统集成了本文的 P-RAG 框架以及 LoRA 微调后的模型，能够有效地理解用户的问题，并生成逻辑清晰的回答，为用户提供流畅、直观的交互体验。图 7 中展示了本文电力领域知识问答系统的示例，图 8 和图 9 分别展示了使用 DeepSeek 与 ChatGLM 大模型的问答示例。当询问“在电气操作中发生什么情况时则构成事故？”这一问题时，本文模型给出的答案涵盖设备误操作和错误调度指挥层面的事故情形，展现了较高的专业度与准确性。相比之下，虽然 DeepSeek 与 ChatGLM 模型生成的答案更加流畅，但是明显存在信息遗漏，它们只列举了常见的误操作情形并解释了其危险后果，但是遗漏了“下达错误调度命令”“错误安排运行方式”等事故情形。

图 7 电力领域知识问答系统示例

Fig.7 Question-answering example by the proposed method

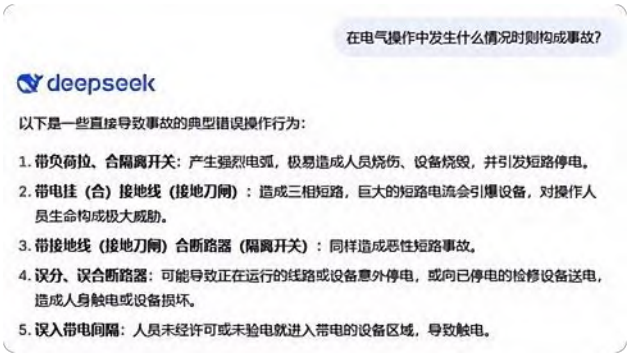

图 8 DeepSeek 模型问答示例

Fig.8 Question-answering example by DeepSeek model

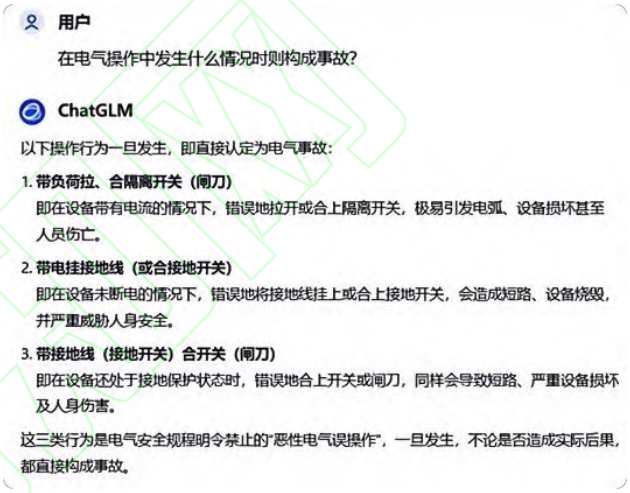

图 9 ChatGLM 模型问答示例

Fig.9 Question-answering example by ChatGLM model

4 结论

本文针对难以从电力领域海量信息中高效获取所需知识，以及大语言模型在电力领域由于知识不足导致的“幻觉”问题，提出了一种基于大语言模型的电力领域知识问答方法，通过知识库增强与参数高效微调的双重机制，提升大语言模型在电力领域问答的准确性。首先构建了一个 P-RAG 框架，使用本文所提自适应文本信息提取方法与层级结构切分策略构建高质量电力知识库，并结合提示工程引导模型生成准确回复。在此基础上，利用大语言模型扩充微调样本集，构建与检索增强机制实际输入结构一致的训练样本，并使用 LoRA 微调进一步加强模型对电力专业知识的理解能力。实验结果表明，所有参评模型结合 P-RAG 框架后，其电力领域知识问答性能均取提升了 15.2%～23.8%，再使用本文所提微调方法对模型进行微调后，性能进一步提升约 2.4%～12.4%。本文所提方法为大语言模型在电力系统更复杂任务中的应用奠定了基础，未来有望辅

助电网智能仿真和复杂故障诊断等场景，推动电力系统的智能化发展。未来的研究将进一步探索如何优化检索策略以提高捕获相关信息的精度，以及如何构建思维链处理更复杂的电力领域知识问答。

参考文献

[1] 国家发展改革委，市场监管总局，生态环境部. 关于进一步强化碳达峰碳中和标准计量体系建设行动方案（2024—2025 年）的通知[EB/OL]. (2024-07-14) [2025-09-01]. https://www.gov.cn/zhengce/zhengceku/202408/content_6967197.htm.

[2] 高洪超，康重庆，李嘉宇，等. 新型电力系统下虚拟电厂的技术演进研判与运营挑战分析[J]. 电工技术学报, 2025, 40(19): 6057-6071.
Gao Hongchao, Kang Chongqing, Li Jiayu, et al. Analysis of technological evolution and operational challenges for virtual power plants in new power systems[J]. Transactions of China Electrotechnical Society, 2025, 40(19): 6057-6071.

[3] 张思慧，宋文胜，唐涛，等. 一种基于数字孪生的灰盒单相 PWM 整流器建模与健康参数监测方法[J]. 电工技术学报, 2025, 40(2): 463-476.
Zhang Sihui, Song Wensheng, Tang Tao, et al. A gray-box single-phase PWM rectifier modeling and health parameter monitoring method based on digital twins[J]. Transactions of China Electrotechnical Society, 2025, 40(2): 463-476.

[4] 金亮，苏浩展，郭劭男，等. 基于 AI 的电磁场计算建模研究综述[J]. 电工技术学报，2025，40(10): 3013-3029.
Jin Liang, Su Haozhan, Guo Shaonan, et al. A review of AI-based computational modelling studies of electromagnetic fields[J]. Transactions of China Electrotechnical Society, 2025, 40(10): 3013-3029.

[5] 田萱，吴志超. 基于信息检索的知识库问答综述[J]. 计算机研究与发展, 2025, 62(2): 314-335.
Tian Xuan, Wu Zhichao. Review of knowledge base question answering based on information retrieval[J]. Journal of Computer Research and Development, 2025, 62(2): 314-335.

[6] 刘雨蒙，赵怡婧，王碧聪，等. 结构化数据库查询语言智能合成技术研究进展[J]. 计算机科学，2024, 51(7): 40-48.
Liu Yumeng, Zhao Yijing, Wang Bicong, et al. Advances in SQL intelligent synthesis technology[J]. Computer Science, 2024, 51(7): 40-48.

[7] Chang Sijie, Wan Meng, Wang Jiaxiang, et al. Engineering material failure analysis report generation based on QWen and Llama2[J]. Results in Engineering, 2025, 26: 104532.

[8] Xiong Luolin, Wang Haofen, Chen Xi, et al. DeepSeek: paradigm shifts and technical evolution in large AI models[J]. IEEE/CAA Journal of Automatica Sinica, 2025, 12(5): 841-858.

[9] Ren Xinyuan, Song Yilin, Yan Chenwei, et al. CMed-baichuan: task explanation-enhanced prompt method onPromptCBLUE benchmark[C]//Health Information Processing: Evaluation Track Papers, 9th China Conference, CHIP 2023, Hangzhou, China, 2024: 31-48.

[10] Zeng Zijian, Ratnavelu K. Deep learning-driven enhancement of chatbot interaction: a comprehensive study on ChatGLM[J]. WSEAS Transactions on Computer Research, 2024, 12: 377-383.

[11] Acharya K, Velasquez A, Song H H. A survey on symbolic knowledge distillation of large language models[J]. IEEE Transactions on Artificial Intelligence, 2024, 5(12): 5928-5948.

[12] Bai Ye, Yi Jiangyan, Tao Jianhua, et al. Fast end-to-end speech recognition via non-autoregressive models and cross-modal knowledge transferring from BERT [J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 1897-1911.

[13] 文森，钱力，胡懋地，等. 基于大语言模型的问答技术研究进展综述[J]. 数据分析与知识发现，2024, 8(6): 16-29.
Wen Sen, Qian Li, Hu Maodi, et al. Review of research progress on question-answering techniques based on large language models[J]. Data Analysis and Knowledge Discovery, 2024, 8(6): 16-29.

[14] 黄君豪，朱锦文，向宗元，等. 大语言模型引导的文本摘要技术与系统[J]. 计算机应用，2024, 44(增刊1): 29-33.
Huang Junhao, Zhu Jinwen, Xiang Zongyuan, et al. Large language model guided text summarization technology and system[J]. Journal of Computer Applications, 2024, 44(S1): 29-33.

[15] 孙光耀，赵志枭，沈思，等. 基于大语言模型的人文

社会科学汉英机器翻译研究[J]. 数据分析与知识发现, 2025, 9(4): 32-45.
Sun Guangyao, Zhao Zhixiao, Shen Si, et al. Optimizing Chinese-English machine translation for humanities and social sciences via large language models[J]. Data Analysis and Knowledge Discovery, 2025, 9(4): 32-45.

[16] 蒲天骄，赵琦，王新迎. 电力人工智能技术研究框架、应用现状及展望[J]. 电网技术，2025，49(5): 1751-1770.
Pu Tianjiao, Zhao Qi, Wang Xinying. Technology framework, application status and prospects on electric power artificial intelligence[J]. Power System Technology, 2025, 49(5): 1751-1770.

[17] 籍欣萌，昝红英，崔婷婷，等. 大模型在垂直领域应用的现状与挑战[J]. 计算机工程与应用，2025，61(12): 1-11.
Ji Xinmeng, Zan Hongying, Cui Tingting, et al. Status and challenges of large language models applications in vertical domains[J]. Computer Engineering and Applications, 2025, 61(12): 1-11.

[18] 牛泽原，李嘉媚，艾芊. 大语言模型在电力系统中的应用初探[J]. 电网技术, 2025, 49(4): 1327-1336.
Niu Zeyuan, Li Jiamei, Ai Qian. Preliminary exploration of the application of large language models in power systems[J]. Power System Technology, 2025, 49(4): 1327-1336.

[19] 刘雪颖，云静，李博，等. 基于大型语言模型的检索增强生成综述[J]. 计算机工程与应用，2025，61(13): 1-25.
Liu Xueying, Yun Jing, Li Bo, et al. Survey of retrieval-augmented generation based on large language models[J]. Computer Engineering and Applications, 2025, 61(13): 1-25.

[20] Wan Yuwei, Chen Zheyuan, Liu Ying, et al. Empowering LLMs by hybrid retrieval-augmented generation for domain-centric Q&A in smart manufacturing[J]. Advanced Engineering Informatics, 2025, 65: 103212.

[21] Boateng G O, Sami H, Alagha A, et al. A survey on large language models for communication, network, and service management: application insights, challenges, and future directions[J]. IEEE Communications Surveys & Tutorials, 2026, 28: 527-566.

[22] Qian Hongjin, Liu Zheng, Mao Kelong, et al. Grounding language model with chunking-free in-context retrieval[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Bangkok, Thailand2024: 1298-1311.

[23] Petrov A V, MacAvaney S, MacDonald C. Shallow cross-encoders forLow-latency retrieval[C]//Advances in Information Retrieval. Cham: Springer, 2024: 151-166.

[24] Islam S, Elmekki H, Elsebai A, et al. A comprehensive survey on applications of transformers for deep learning tasks[J]. Expert Systems with Applications, 2024, 241: 122666.

[25] Zhu Yutao, Yuan Huaying, Wang Shuting, et al. Large language models for information retrieval: a survey[J]. 2025, 44(1): 1-54.

[26] 张钦彤，王昱超，王鹤羲，等. 大语言模型微调技术的研究综述[J]. 计算机工程与应用，2024，60(17): 17-33.
Zhang Qintong, Wang Yuchao, Wang Hexi, et al. Comprehensive review of large language model fine-tuning[J]. Computer Engineering and Applications, 2024, 60(17): 17-33.

[27] 秦董洪，李政韬，白凤波，等. 大语言模型参数高效微调技术综述[J]. 计算机工程与应用，2025，61(16): 38-63.
Qin Donghong, Li Zhengtao, Bai Fengbo, et al. Review of parameter-efficient fine-tuning technology for large language models[J]. Computer Engineering and Applications, 2025, 61(16): 38-63.

[28] Chen Huiqiang, Zhu Tianqing, Liu Bo, et al. Fine-tuning a biased model for improving fairness[J]. IEEE Transactions on Big Data, 2025, 11(3): 1397-1410.

[29] Inoue N, Otake S, Hirose T, et al. ELP-adapters: parameter efficient adapter tuning for various speech processing tasks[J]. 2024, 32: 3867-3880.

[30] Mou Shangyang, Xue Qiang, Chen Xunquan, et al. Prefix tuning with prompt augmentation for efficient financial news summarization[J]. Journal of Computational Social Science, 2024, 8(1): 19.

[31] Balasubramanian P, Liyana S, Sankaran H, et al. Generative AI for cyber threat intelligence: applications, challenges, and analysis of real-world

case studies[J]. Artificial Intelligence Review, 2025, 58(11): 336.

[32] Liu Xiaoyang, Zhu Rongyi, Zha Daochen, et al. Differentially private low-rank adaptation of large language model using federated learning[J]. 2025, 16(2): 1-24.

[33] 丁俐夫，陈颖，肖谭南，等. 基于大语言模型的新型电力系统生成式智能应用模式初探[J]. 电力系统自动化, 2024, 48(19): 1-13.
Ding Lifu, Chen Ying, Xiao Tannan, et al. Exploration of generative intelligent application mode for new power systems based on large language models[J]. Automation of Electric Power Systems, 2024, 48(19): 1-13.

[34] Xia Shujun, Hua Qing, Mei Zihan, et al. Clinical application potential of large language model: a study based on thyroid nodules[J]. Endocrine, 2025, 87(1): 206-213.

[35] Zhang Tianyi, Kishore V, Wu F. BERTScore: evaluating text generation with BERT[C]//8th International Conference on Learning Representations, Addis Ababa, Ethiopia, 2020: 5333-5376.

作者简介

杨　燕　女，1995 年生，讲师，硕士生导师，研究方向为人工智能、电力系统分析。

E-mail：yanyang@cqupt.edu.cn（通信作者）

刘　豪　男，2000 年生，硕士研究生，研究方向为大模型技术在电力系统中的应用。

E-mail：s240201067@stu.cqupt.edu.cn

Knowledge Question-Answering Method in Power Field Based on Large Language Models

Yang Yan[1,2]　*Liu Hao*[1,2]　*Song Jie*[3]　*Wu Yi*[3]

（1. School of Computer Science and Technology　Chongqing University of Posts and Telecommunications　Chongqing　400065　China

2. Chongqing Key Laboratory of Computational Intelligence　Chongqing University of Posts and Telecommunications　Chongqing　400065　China

3. State Grid Shanghai Municipal Electric Power Company　Shanghai　200122　China）

Abstract　Efficient and accurate acquisition of required knowledge from massive power field information sources poses a significant challenge to knowledge management in the power industry. Large language models (LLMs) have achieved breakthroughs in natural language understanding and generation, offering new avenues for knowledge question-answering. However, their application in the power field remains limited, as they struggle to comprehend specialized concepts and are prone to generating hallucinations. To address these issues, this paper proposes a knowledge question-answering method in the power field based on LLMs. This method improves the answer accuracy by integrating domain-specific knowledge bases with parameter-efficient fine-tuning optimization.

Firstly, this paper constructs a power field knowledge question-answering framework based on retrieval-augmented generation(P-RAG). This framework employs an adaptive text information extraction method based on LLMs to efficiently parse power document layouts and extract text. It then recursively segments the text based on hierarchical document titles to ensure semantic integrity, building a high-quality power field knowledge base. On this basis, prompt engineering guides the LLM to fully comprehend and utilize this power knowledge, thereby improving question-answering accuracy. Secondly, this paper proposes a model optimization method based on sample augmentation and LoRA fine-tuning. This method utilizes LLMs to rewrite and expand original question-answering pairs, diversifying textual expressions without altering the semantics, thereby effectively resolving the scarcity of fine-tuning samples. Meanwhile, the question and retrieved relevant knowledge are combined as the training input vector to construct a sample structure consistent with the actual input of the P-RAG framework. Through LoRA fine-tuning, the understanding of power field knowledge by

LLMs and their ability to utilize external retrieved information are enhanced.

Comparative tests on a series of LLMs, including BaiChuan2-7B, BlueLM-7B, Qwen-7B, ChatGLM3-6B, and DeepSeek-R1-7B, show that after integration with the P-RAG framework, the performance of all participating models in power field knowledge question-answering tasks improved by 15.2% to 23.8%. This verifies the universality and effectiveness of the P-RAG framework. Furthermore, based on Qwen-1.8B, Qwen-7B, and ChatGLM3-6B models, different fine-tuning optimization methods are compared. The results show that after standard LoRA fine-tuning optimization method, model performance decreased by approximately 3.5% to 10.4%. In contrast, applying the proposed optimization method can improve the model performance by 2.4% to 12.4%, validating the effectiveness of the proposed sample-augmentation fine-tuning optimization method.

The following conclusions can be drawn from the experimental analysis: (1) The proposed P-RAG framework provides external professional power knowledge for general LLMs, alleviating the hallucination problem of LLMs in the power field. (2) Compared with standard LoRA fine-tuning, the proposed model optimization method is more suitable for the P-RAG framework. Since the training sample input is consistent with the actual input of the P-RAG framework, it enhances the ability of LLMs to utilize external information and improves question-answering accuracy.

Keywords： Large language models, power knowledge question-answering, retrieval-augmented generation, sample augmentation, parameter-efficient fine-tuning